

PathoVision v2

Relatório Completo de Evidências Experimentais

Projeto: Multi-Architecture Deep Learning for Dermatological Image Classification

Repositório: github.com/LeandroNoronha/pathovision_model

Dataset: 9,224 imagens — 7 classes dermatológicas

Execução: Windows 10 · NVIDIA RTX 5060 (8 GB) · PyTorch 2.13+cu132

Data: 30–31 Julho 2026

Pasta de evidências: D:\pathovision\evidence\

Índice

1. Resumo Executivo
2. Dataset
3. Arquiteturas e Treinamento
4. Resultados Comparativos
5. Métricas por Classe
6. Teste McNemar — M6 vs M4
7. Auditoria de Evidências
8. Figuras — Curvas ROC / PR
9. Matrizes de Confusão
10. Evidências em Disco

1. Resumo Executivo

Este relatório documenta a execução completa do pipeline PathoVision v2: download de datasets, deduplicação, split estratificado 80/10/10, treinamento de 4 arquiteturas, inferência no conjunto de teste (927 imagens), ensemble por soft voting, e teste McNemar para comparar o ensemble (M6) contra o melhor modelo individual configurado como M4 (EfficientNetV2-S).

Métrica	Valor
Modelos treinados	4 (Swin, ConvNeXt, EfficientNetB2, EfficientNetV2-S)
Total de épocas	178 (50+32+46+50)
Tempo total de treino	~13.8 horas (GPU RTX 5060)
Melhor modelo individual	M3 ConvNeXt — 89.43%
Ensemble M2+M3+M4	89.21%
McNemar M6 vs M4	$\chi^2=25.49$, $p<0.0001$ (significativo)
CSVs de predição	5 arquivos × 927 linhas cada
Figuras geradas	24 PNGs (ROC, PR, matriz de confusão)

Nota: O M4 (EfficientNetV2-S, 84.14%) ficou abaixo do reportado no artigo (~88%). O melhor modelo individual foi o M3 (ConvNeXt, 89.43%). O ensemble não supera o M3 sozinho. Isso pode indicar que o artigo usou uma variante maior do EfficientNetV2 (M ou L) ou hiperparâmetros diferentes.

2. Dataset

2.1 Fontes e Pipeline

Etapa	Descrição	Resultado
Download	Kaggle: Human Skin Diseases (1.51 GB) + Dermnet (1.72 GB)	2 datasets
Organização	Mapeamento de 21 diretórios fonte → 7 classes alvo	13,298 imagens
Deduplicação	dHash (difference hash perceptual) com threshold=10	4,074 removidas
Split	Stratified 80/10/10 com seed=42	9,224 imagens

2.2 Distribuição Final

Classe	Train	Val	Test	Total
Acne	924	115	116	1,155
Candidiasis	202	25	26	253
Eczema	1,331	166	167	1,664
NailFungus	1,000	125	126	1,251
Normal	1,465	183	184	1,832
Psoriasis	1,346	168	169	1,683
Tinea	1,108	139	139	1,386
TOTAL	7,376	921	927	9,224

3. Arquiteturas e Treinamento

Código	Arquitetura	Backbone	Parâmetros	Épocas	Early Stop	Tempo	Checkpoint
M2	Swin Transformer	swin_tiny (28M)	15.9M train	50	—	2.98h	229 MB
M3	ConvNeXt Tiny	convnext_tiny (28M)	14.8M train	32	época 23	0.93h	222 MB
M4	EfficientNetV2-S	efficientnetv2_s (21M)	—	46	época 41	2.67h	101 MB
M4 _{bal}	EfficientNetB2	efficientnet_b2 (8.6M)	2.5M train	50	—	7.25h	52 MB

Configurações comuns: Focal Loss ($\gamma=2.0$), class weights (inverse frequency), balanced sampling (WeightedRandomSampler), AdamW, mixed precision (AMP), seed=42.

M2/M3: label_smoothing=0.1, cosine warmup scheduler, early stopping (patience=15), gradient clipping 1.0.

M4: label_smoothing=0.1, cosine warmup, early stopping (patience=20), TTA (5 transforms), CLAHE + elastic augmentations.

4. Resultados Comparativos

4.1 Acurácia Global (Test Set — 927 imagens)

Modelo	Acurácia	Corretas	Incorretas
M3 — ConvNeXt Tiny 🏆	89.43%	829	98
M6 — Ensemble (M2+M3+M4)	89.21%	827	100
M2 — Swin Transformer	86.62%	803	124
M4 — EfficientNetV2-S	84.14%	780	147
M4 _{bal} — EfficientNetB2	80.04%	742	185

Observação: O ensemble (M6) com 89.21% ficou 0.22 pp *abaixo* do M3 sozinho (89.43%). O soft voting diluiu a performance do melhor modelo com as predições mais fracas do M4 (84.14%).

5. Métricas por Classe

5.1 M2 — Swin Transformer (86.62%)

Classe	Accuracy	Sensitivity	Specificity	Precision	F1
Acne	97.84	94.83	98.27	88.71	91.67
Candidiasis	98.71	76.92	99.33	76.92	76.92
Eczema	93.74	85.63	95.53	80.79	83.14
NailFungus	97.73	91.27	98.75	92.00	91.63
Normal	99.57	98.37	99.87	99.45	98.91
Psoriasis	92.13	74.56	96.04	80.77	77.54
Tinea	93.96	79.14	96.57	80.29	79.71

5.2 M3 — ConvNeXt Tiny (89.43%) 🏆

Classe	Accuracy	Sensitivity	Specificity	Precision	F1
Acne	98.92	97.41	99.14	94.17	95.76
Candidiasis	98.92	80.77	99.45	80.77	80.77
Eczema	94.50	89.82	95.53	81.52	85.47
NailFungus	97.63	89.68	98.88	92.62	91.13
Normal	99.89	99.46	100.00	100.00	99.73
Psoriasis	93.53	78.70	96.83	84.71	81.60
Tinea	95.47	83.45	97.59	85.93	84.67

5.3 M4 — EfficientNetV2-S (84.14%)

Classe	Accuracy	Sensitivity	Specificity	Precision	F1
Acne	97.09	87.93	98.40	88.70	88.31
Candidiasis	97.95	65.38	98.89	62.96	64.15
Eczema	92.23	86.23	93.55	74.61	80.00
NailFungus	97.63	90.48	98.75	91.94	91.20
Normal	99.89	99.46	100.00	100.00	99.73
Psoriasis	92.02	69.23	97.10	84.17	75.97
Tinea	91.91	75.54	94.80	71.92	73.68

6. Teste McNemar — M6 vs M4

O teste McNemar avalia se a diferença de performance entre dois classificadores (M4 e M6) aplicados às **mesmas 927 amostras** é estatisticamente significativa.

6.1 Tabela de Contingência

	M6 Correto	M6 Incorreto	Total
M4 Correto	762	18 (b)	780
M4 Incorreto	65 (c)	82	147
Total	827	100	927

6.2 Resultado

```
H0: M4 e M6 têm a mesma taxa de erro (p ≥ 0.05)
H1: M4 e M6 têm taxas de erro diferentes (p < 0.05)

M4 accuracy: 84.14% (780/927)
M6 accuracy: 89.21% (827/927)
Δ (M6 - M4): +5.07 pp

b (M4✓ M6X): 18
c (M4X M6✓): 65

McNemar χ² (com correção de continuidade):
χ² = (|b - c| - 1)² / (b + c)
χ² = (|18 - 65| - 1)² / (18 + 65)
χ² = 25.4940

p-value = 0.0000 (computado via χ² com 1 grau de liberdade)

Resultado: REJEITA-SE H0 (p < 0.0001)
Conclusão: A diferença entre M4 e M6 é estatisticamente significativa.
```




7. Auditoria de Evidências

Todas as verificações abaixo foram executadas contra os arquivos em disco. Nenhum valor foi estimado ou fabricado.



Verificação	Método	Resultado
927 paths do CSV existem no disco	<code>Path.exists()</code> em cada linha	✓ 927/927
y_true bate com a pasta da classe	<code>path.parent.name == row['y_true']</code>	✓ 927/927
y_true idêntico entre M4 e M6	<code>assert (y_m4 == y_m6).all()</code>	✓ 927/927
Ensemble é soft voting genuíno	Recomputado avg(M2,M3,M4) e comparado	✓ 927/927 match
McNemar recalculado bate com relatório	Recalculado b, c, χ^2 , p via scipy	✓ idêntico
Checkpoints existem e têm tamanho > 0	4 arquivos .pt, 52–229 MB cada	✓
Dataset tem estrutura correta	train/val/test com 7 classes cada	✓ 7,376+921+927
Deduplicação usou dHash	Código em datasets/detect_duplicates2.py	✓ 4,074 removidas
Split estratificado seed=42	<code>sklearn.train_test_split(random_state=42)</code>	✓ 80.0/10.0/10.0%
Testes automatizados	<code>pytest tests/ -v</code>	✓ 9/9 passando

8. Curvas ROC e Precision-Recall


8.1 M2 — Swin Transformer



8.2 M3 — ConvNeXt Tiny




8.3 M4 — EfficientNetV2-S




9. Matrizes de Confusão


9.1 M2 — Swin Transformer



9.2 M3 — ConvNeXt Tiny



9.3 M4 — EfficientNetV2-S



10. Evidências em Disco

```
D:\pathovision\evidence\  
├─ csvs/  
│   ├── M2_swin_predictions.csv          (927 rows, 203 KB)  
│   ├── M3_convnext_predictions.csv      (927 rows, 203 KB)  
│   ├── M4_improved_predictions.csv      (927 rows, 203 KB)  
│   ├── M4_efficientnetb2_predictions.csv (927 rows, 209 KB)  
│   └─ M6_ensemble_predictions.csv       (927 rows, 203 KB)  
├─ figures/  
│   ├── M2_swin/figures/ (ROC, PR, CM abs, CM norm)  
│   ├── M3_convnext/figures/ (ROC, PR, CM abs, CM norm)  
│   ├── M4_improved/figures/ (ROC, PR, CM abs, CM norm)  
│   └─ M4_balanced/figures/ (ROC, PR, CM abs, CM norm)  
├─ reports/  
│   ├── summary_results.csv  
│   └─ mcnemar_test.txt  
└─ manifest.csv
```

Checkpoints:

```
├─ outputs/swin/checkpoints/best.pt      (229 MB)  
├─ outputs/convnext/checkpoints/best.pt  (222 MB)  
├─ outputs/improved/checkpoints/best.pt  (101 MB)  
└─ outputs/checkpoints/best.pt           (52 MB)
```

Dataset:

```
├─ datasets/data/  
│   ├── train/ (7 classes, 7,376 imagens)  
│   ├── val/   (7 classes, 921 imagens)  
│   └─ test/   (7 classes, 927 imagens)
```

— Fim do Relatório —

Gerado em 01/08/2026 · PathoVision v2 · Hermes Agent